

Развој система за генерисање садржаја заснованог на подацима из игре *Elden Ring*

Марко Ердељи

Душан Рожић

Јелена Миковић

Софтверско инжењерство и информационе технологије

Универзитет у Новом Саду, Факултет техничких наука

Нови Сад, Србија

erdelji.r24.2024@uns.ac.rs, rozic.r239.2024@uns.ac.rs, mikovic.r235.2024@uns.ac.rs

Sažetak—Овај рад представља развој система за генерисање садржаја заснованог на подацима из игре *Elden Ring*, уз фокус на припрему података, обраду и евалуацију генеративних модела. Описана је методологија прикупљања и препроцесирања визуелних и текстуалних података, примена напредних модела попут CLIP-а и BLIP-2, као и евалуација перформанси коришћењем квантитативних и квалитативних метрика. Кључни доприноси укључују креирање квалитетног скупа података и оптимизацију процеса генерисања садржаја, са потенцијалном применом у креирању персонализованих визуелних елемената. Рад наглашава важност прецизног мапирања између визуелног и текстуалног модалитета за унапређење генеративних модела.

I. Увод

Развој система за аутоматско генерисање слика ликова из видео-игара представља један од савремених изазова у области машинског учења и рачунарске графике. Ова област истраживања комбинује напредне технике обраде података и генеративне моделе како би се створиле визуелно реалистичне и стилски конзистентне слике на основу специфичних захтева. Такви системи имају широку примену у индустрији видео-игара, филмској продукцији и дизајну дигиталног садржаја, што доприноси бржем процесу дизајна, смањењу трошкова и персонализацију визуелних елемената. Недавни напредак у генеративним моделима допринео је стварању алата који могу генерисати висококвалитетне слике, али изазови у вези са специфичношћу стила и контекста и даље остају.

Овај проблем је важан јер омогућава аутоматизацију и оптимизацију процеса креирања дигиталних ликова. Постојећи приступи често захтевају ручно подешавање или велике количине података за обуку, што може бити ресурсно интензивно. Поред тога, генерисање слика које прецизно одражавају естетику специфичне игре, попут мрачног и детаљног света игре *Elden Ring*¹, представља изазов због потребе за очувањем стилске аутентичности и визуелне конзистентности. Овај рад настоји да адресира ове изазове кроз развој система који може ефикасно генерисати слике прилагођене естетици одређене игре.

¹*Elden Ring* је акционо-улога игра коју је развио FromSoftware и објавио Bandai Namco Entertainment 2022. године. Позната је по свом богатом фантазијском свету, сложеном наративу и карактеристичном визуелном стилу који комбинује мрачну фантазију са детаљним оклопима, оружјем и окружењем.

У овом раду фокус је на развоју система за аутоматско генерисање слика ликова из видео-игре *Elden Ring*, са циљем стварања визуелног садржаја који одговара специфичној естетици игре, укључујући карактеристичне оклопе, оружја и атмосферу света. Проблем се своди на прилагођавање генеративних модела тако да генеришу слике високог квалитета које су стилски усклађене са датим контекстом, уз ограничења везана за доступност података и рачунске ресурсе.

Рад је организован тако да прво објашњава основне теоријске појмове везане за генеративне моделе и њихову адаптацију, затим описује процес прикупљања и припреме података, као и методологију коришћења током обуке и евалуације модела. У завршном делу приказани су резултати, анализа добијених слика и могући правци даљег развоја система.

II. Теоријске основе

Дифузиони модели представљају класу генеративних модела који омогућавају стварање сложених података, попут слика, кроз итеративни процес уклањања шума из насумичних података. Основна идеја заснива се на постепеном додавању шума оригиналним подацима током више корака, након чега се модел обучава да обрне тај процес и на тај начин генерише реалистичне слике [1]. *Stable Diffusion* унапређује овај приступ увођењем латентног простора, што значајно смањује рачунске захтеве и омогућава креирање висококвалитетних слика на основу текстуалних описа [2].

За прилагођавање дифузионих модела специфичним доменима користи се техника *LoRA* (Low-Rank Adaptation), која омогућава ефикасан *fine tuning* додавањем нискорангованих ажурирања у тежине модела. На овај начин смањује се потреба за великим количинама података и рачунских ресурса, што ову методу чини посебно погодном за прилагођавање моделима специфичних визуелних стилова [3].

Мултимодално учење омогућава интеграцију визуелних и текстуалних информација, што је од посебног значаја за повезивање слика са њиховим описима. Модел CLIP²

²CLIP (*Contrastive Language-Image Pretraining*) је модел који повезује визуелне и текстуалне податке кроз контрастно учење.

користи контрастно учење за мапирање слика и текста у заједнички простор, чиме се омогућава филтрирање визуелног садржаја на основу текстуалних упита [4]. Слично томе, *BLIP-2*³ комбинује визуелни и језички модул како би се генерисали детаљни текстуални описи слика, који могу бити коришћени у обуци генеративних модела [5]. Велики језички модели додатно доприносе прецизности описа, што омогућава боље резултате у процесу даље обраде [6].

Zero-shot учење омогућава моделу да препознаје или генерише садржај за класе које није видео током обуке, користећи семантичке информације попут текстуалних описа [7]. Овај приступ користи мапирање између визуелних и текстуалних простора како би модел генерализовао на нове задатке без додатног тренинга.

Прикупљање података из онлајн извора, познато као *web scraping*⁴, представља један од начина прикупљања скупова података за обуку модела [8]. Овај процес подразумева аутоматизовано преузимање слика и метаподатака, уз неопходно поштовање етичких аспеката попут ограничења броја упита и правила коришћења [9].

Fréchet Inception Distance (FID) се користи за евалуацију генеративних модела. Ова метрика упоређује визуелни квалитет стварних и генерисаних слика на основу карактеристика издвојених из *InceptionV3* мреже [10], заснована на *Fréchet* дистанци дефинисаној за мултиваријантне нормалне дистрибуције [11]. FID се рачуна према формули:

$$FID = \|\mu_r - \mu_g\|^2 + \text{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2})$$

где је μ_r средња вредност карактеристика стварних слика, μ_g средња вредност карактеристика генерисаних слика, Σ_r и Σ_g су коваријансне матрице стварних и генерисаних слика, респективно, а Tr представља траг матрице. Ниже вредности *FID*-а указују на већу сличност са стварним сликама.

III. Сродни радови

У досадашњој литератури заступљени су бројни радови који истражују примену дифузионих модела и мултимодалног учења у генерисању визуелног садржаја. На пример, рад [12] приказује употребу *LoRA* методе за брзи *fine tuning Stable Diffusion* модела у доменима специфичних визуелних концепата, као што су ликови у фантастичним окружењима. Овај приступ омогућава креирање слика са конзистентним стилем уз минималне ресурсе, што је послужило као инспирација за методе примењене у овом раду.

Рад [13] бави се генерисањем слика специфичних ликова применом *LoRA*, при чему је нагласак на детаљима као што су текстуре и композиције у фантастичним доменима. Слично томе, у [14] предлаже се комбиновање више *LoRA* модела ради креирања сложених визуелних сцена.

³*BLIP-2* је модел за генерисање текстуалних описа на основу визуелног садржаја, комбинујући визуелни и језички модул.

⁴*Web scraping* подразумева аутоматизовано прикупљање података са веб страница коришћењем програмских алата.

Рад [15] описује примену дифузионих модела и *CLIP*-а у систему *DALL-E 2* за генерисање слика из текстуалних описа, са фокусом на хијерархијско моделовање. Овај приступ је инспирисао методе за комбиновање текстуалних и визуелних информација у генеративним системима.

IV. Скуп података

Правилна припрема скупа података кључна је за успешно тренирање генеративних модела. Ово поглавље описује процес прикупљања, чишћења и препроцесирања података о ликовима из игре *Elden Ring*, као и генерисање текстуалних описа који повезују визуелни и текстуални модалитет.

A. Извори података

Примарни извор визуелних података био је *Elden Ring Wiki* [?], који пружа опсежну базу слика и информација о главним непријатељима и значајним ликовима. За прикупљање слика коришћени су алати за *web scraping*, укључујући Python библиотеке *Requests* и *BeautifulSoup*. Посебна пажња посвећена је етичким смерницама, укључујући ограничавање учесталости упита (*rate-limiting*) и избегавање преузимања непотребних ресурса [?].

B. Процес прикупљања и чишћења података

Прикупљање података обављено је у четири корака:

- 1) Идентификација релевантних страница са информацијама о ликовима и њиховим визуелним приказима.
- 2) Екстракција метаподатака: имена лика, URL-а странице, описа и главне слике.
- 3) Преузимање и чување слика у стандардизованој локалној структури.
- 4) Чување метаподатака у JSON формату ради лакше репродукције и обраде.

Да би се смањила редунација, примењена је дедупликација [?]. Први ниво дедупликације спроводио се коришћењем скупа виђених имена како би се спречило понављање ликова. Други ниво филтрирања користио је модел *CLIP* за проверу сличности слика, бирајући само оне са највишим степеном семантичке усклађености са унапред дефинисаним упитом. Овај процес осигурао је баланс између количине и квалитета података.

C. Препроцесирање

За припрему слика за тренинг модела спроведени су следећи кораци:

- 1) Нормализација формата и резолуције – све слике су трансформисане на уједначене димензије уз централно исецање (*crop*⁵) и хоризонталну аугментацију за повећање разноврсности.
- 2) Стандардизација имена фајлова – функција за генерисање јединствених имена фајлова како би се избегли конфликти.

⁵*Crop* означава процес исецања слике ради уклањања непотребних делова и прилагођавања димензија.



Слика 1: Процесни ток од HTTP захтева до текста

3) Балансирање квалитета – филтрирање помоћу *CLIP* модела.

Ови кораци осигуравају уједначеност скупа података, елиминацију дупликата и спремност за тренинг процедуре.

D. Генерисање текстуалних описа

За повезивање слика са текстуалним описима коришћен је модел *BLIP-2 (Bootstrapping Language-Image Pretraining)*. Овај модел омогућава генерисање детаљних описа на основу визуелног садржаја. За сваку слику постављена су питања о физичким карактеристикама, оружју, оклопу и окружењу, чиме се обезбеђују свеобухватни описи ликова. Генерисани описи чувају се у JSON формату и користе за тренинг генеративних модела. Додатно, описи су рафинирани коришћењем великих језичких модела (нпр. *GPT-4*) ради:

- стандардизације терминологије,
- структурирања у атрибуте,
- креирања краћих, оптимизованих упита за моделе дифузије.

Овај приступ омогућава прецизно мапирање између визуелног и текстуалног модалитета, побољшавајући квалитет генеративних слика.

V. Методологија

A. Прикупљање података

За обезбеђивање квалитетног скупа података за тренинг генеративних модела, развијен је систем који покрива процес од прикупљања слика до њихове филтрације, анотације и обраде текстуалних описа. Описана су три кључна сегмента: (1) прикупљање и филтрирање података помоћу *CLIP*-а, (2) генерисање и обрада описа, (3) структура базе података и анотација.

1) *Прикупљање података*: На слици 1 је приказано прикупљање података. Прикупљање података са веб-странице се на аутоматизованом процесу који укључује:

- 1) Преузимање садржаја са страница коришћењем библиотеке *Requests*.
- 2) Парсирање HTML структуре помоћу *BeautifulSoup* за издвајање кључних елемената: имена лика, URL-а, главне слике и основног описа.
- 3) Генерисање јединствених идентификатора и безбедних имена фајлова за спречавање дупликата.

Модел *CLIP* користи се за филтрирање слика. За слику I и текстуални упит T , добијају се вектори e_I и e_T , а сличност се мери косинусном сличношћу [?]:

$$\cos(e_I, e_T) = \frac{e_I \cdot e_T}{\|e_I\| \|e_T\|}$$

CLIP, трениран на великом скупу парова (слика, текст), омогућава препознавање семантичке усклађености између слика и упита [?]. Све прикупљене слике евалуиране су према унапред дефинисаном упиту који описује жељени стил, а косинусна сличност омогућила је селекцију слика које најбоље одговарају естетици игре *Elden Ring*. Овај процес елиминисао је неквалитетне и нерелевантне примере.

2) *Генерисање и обрада текстуалних описа*: За генерисање текстуалних описа коришћен је *BLIP-2*, који комбинује визуелни енкодер, *Q-Former* и језичку мрежу. Визуелни енкодер препознаје објекте на слици, *Q-Former* мапира информације у токене, а језичка мрежа генерише описе или одговоре на питања [5]. Питања су постављана итеративно, покривајући аспекте попут физичког изгледа, оклопа, оружја и окружења, чиме су обезбеђени детаљни описи. Одговори су комбиновани у јединствен опис и сачувани у JSON формату, пружајући већу грануларност у односу на једнофазно генерисање описа.

3) *Структура базе података и анотација*: База података организована је у JSON формату, са ставкама које садрже: име лика, URL странице, локалну путању до слике, иницијални опис, оцену *CLIP*-а и опис генерисан *BLIP-2* моделом. Сlike су додатно препроцесирани:

- скалиране на резолуцију 512×512 пиксела,
- нормализоване,
- аугментирани.

Описи су проширени токеном „<elden-ring>“ за повезивање са специфичним визуелним концептом. Анотације су обogaћене структурираним атрибутима (нпр. облик тела, врста оклопа), што олакшава прецизно тренирање и евалуацију конзистентности између слике и текста.

B. Обука

1) *Stable Diffusion 1.5*: За обуку је коришћен модел *Stable Diffusion 1.5*, који комбинује:

- **латентни аутокодер** (*AutoencoderKL*) за кодирање и декодирање слика,
- **UNet архитектуру** за предвиђање шума током процеса дифузије,
- **CLIP текстуални енкодер** за повезивање текстуалних и визуелних података.

Модел је дообучен применом *LoRA (Low-Rank Adaptation)* технике, која додаје мале адаптивне слојеве у UNet и CLIP енкодер. Овај приступ омогућава ефикасан *fine-tuning* без модификовања оригиналних тежина, уз знатно мању потрошњу меморије и ресурса.

Параметри и конфигурација обуке:

- *LoRA rank*: $r = 4$
- *Прецизност*: FP16
- *Gradient checkpointing*: омогућен ради уштеде меморије
- *Оптимизатор*: AdamW
- *Learning rate*: 1×10^{-5}
- *Batch size*: 4
- *Scheduler*: косинусни распоред смањења стопе учења
- *Максималан број корака*: 1500
- *Интервал чувања модела*: сваких 200 корака

Метод обуке: Обука је спроведена на скупу слика ликов из игре *Elden Ring* са придруженим текстуалним описима. Процес се заснива на *DDPM (Denoising Diffusion Probabilistic Model)* приступу, где UNet учи да предвиди шум који је додат на латентну представу слике.

Кључни кораци током сваког итеративног циклуса су:

- 1) Кодирање слике у латентни простор преко аутокодера.
- 2) Додавање случајног шума на латент.
- 3) Предвиђање шума помоћу UNet-а.
- 4) Израчунавање MSE губитка између стварног и предвиђеног шума.

Резултат: По завршетку обуке, *LoRA* адаптери су издвојени као засебне тежине које се могу накнадно применити на основни *Stable Diffusion* модел. Тако прилагођен модел омогућава генерисање слика које одражавају визуелни стил и атмосферу игре *Elden Ring*.

2) *SDXL 1.0*: За обуку је коришћен модел *SDXL 1.0*, који представља проширену верзију модела *Stable Diffusion* са побољшаном архитектуром и већом дубином неуронске мреже. *SDXL* користи два текстуална енкодера — *CLIP ViT-L* и *CLIP ViT-G* — чији се излази спајају током процеса условљавања, што омогућава боље разумевање сложенијих текстуалних упита и постизање детаљнијих визуелних резултата [16].

Модел је дообучен применом *LoRA (Low-Rank Adaptation)* технике, која додаје мале адаптивне матрице у UNet и CLIP енкодере. Овај приступ омогућава прилагођавање модела специфичном домену без измене оригиналних тежина, уз знатно мање захтеве за меморијом у односу на класичан *fine-tuning*.

Параметри и конфигурација обуке:

- *LoRA rank*: $r = 4$
- *Прецизност*: FP16
- *Gradient checkpointing*: омогућен
- *Оптимизатор*: AdamW
- *Learning rate*: 1×10^{-5}
- *Batch size*: 4
- *Scheduler*: косинусни распоред смањења стопе учења
- *Максималан број корака*: 1500
- *Резолуција слика*: 512×512 пиксела
- *Интервал чувања модела*: сваких 200 корака

Метод обуке: Обука је заснована на *DDPM (Denoising Diffusion Probabilistic Model)* приступу. У сваком кораку,

UNet покушава да реконструише чисту латентну представу слике из шумом нарушеног примера. Процес се одвија у следећим фазама:

- 1) Енкодирање слике у латентни простор помоћу аутокодера.
- 2) Додавање случајног шума на латентну представу.
- 3) Предвиђање шума помоћу UNet мреже условљене текстуалним embedding-ом.
- 4) Израчунавање MSE губитка између предвиђеног и стварног шума.

За разлику од модела *Stable Diffusion 1.5*, *SDXL* има шири UNet са већим бројем attention блокова и два независна текстуална енкодера, што омогућава детаљније репрезентације и стабилније резултате током тренинга.

Резултат: По завршетку обуке, обучени *LoRA* адаптери су издвојени као засебне тежине које се могу накнадно применити на базни *SDXL* модел. Тако прилагођен модел је способан да генерише слике које задржавају карактеристике уметничког стила и атмосфере игре *Elden Ring*, уз виши ниво визуелног квалитета у односу на *Stable Diffusion 1.5*.

VI. Резултати и дискусија

Ова секција приказује резултате евалуације генеративних модела *Stable Diffusion 1.5 (SD 1.5)* и *SDXL 1.0* након *fine-tuning*-а коришћењем *LoRA* технике. Резултати обухватају квантитативну анализу засновану на *Fréchet Inception Distance (FID)* метрици и квалитативну анализу засновану на личној процени генерисаних слика. Резултати су представљени за све кораке тренинга, а дискусија сумира успех процеса и изазове.

A. SD 1.5

FID метрика је коришћена за процену визуелног квалитета генерисаних слика у односу на стварне слике. Табела I приказује *FID* вредности за базни модел и све *LoRA* кораке.

Tabela I: *FID* резултати за SD 1.5

Модел/Корак	FID
SD 1.5 Base	244.9732
LoRA step 200	213.8312
LoRA step 500	199.4403
LoRA step 1000	201.1154
LoRA step 1500	202.0467

Резултати показују да је *fine-tuning* са *LoRA* техником значајно побољшао визуелни квалитет. Најбољи резултат је постигнут на кораку 500 са *FID* вредношћу од 199.44, што представља смањење од приближно 18.5% у односу на базни модел (244.97). Међутим, благи пораст *FID*-а за кораке 1000 и 1500 указује на могући *overfitting*⁶.

⁶*Overfitting* је прекомерно прилагођавање модела подацима за тренинг, што смањује генерализацију.

B. SDXL 1.0

За модел SDXL 1.0, *FID* метрика је такође коришћена за евалуацију. Табела II приказује *FID* вредности за базни модел и све *LoRA* кораке.

Табела II: *FID* резултати за SDXL 1.0

Модел/Корак	FID
SDXL Base	269.2809
LoRA step 200	260.0837
LoRA step 500	230.4458
LoRA step 1000	212.3698
LoRA step 1500	206.5144

Примена *LoRA* довела је до континуираног побољшања визуелног квалитета, са најбољим резултатом на кораку 1500 (*FID* 206.51), што је смањење од око 23.3% у односу на базни модел (269.28).

C. Квалитативна анализа

Квалитативна анализа је спроведена кроз личну процену генерисаних слика, са фокусом на детаље и стилску конзистентност. Најбољи *LoRA* модели (*SD 1.5* на кораку 500 и *SDXL 1.0* на кораку 1500) показују приметно боље детаље и стилску усклађеност у поређењу са базним моделима.


Слике 2 и 3 илуструју упоређивање између базних модела и најбољих *LoRA* корака за оба модела.

D. Дискусија

Резултати показују да је *fine-tuning* са *LoRA* техником био успешан за оба модела, са значајним побољшањем *FID* вредности у односу на базне моделе. За *SD 1.5*, најбољи резултат је постигнут на кораку 500, са смањењем *FID*-а од приближно 18.5% (са 244.97 на 199.44), док је за *SDXL 1.0* оптималан корак био 1500, са смањењем *FID*-а од око 23.3% (са 269.28 на 206.51). Ови резултати потврђују ефикасност *LoRA* у адаптацији модела на специфичне визуелне домене, као што су фантастични ликови и сцене.

Квалитативна анализа је показала да *fine-tuning* доводи до бољих детаља и стилске конзистентности, посебно у генерисању слика са високим нивоом детаља. За *SD 1.5*, уочен је благи пораст *FID*-а након корака 500, што може указивати на *overfitting*. Ово је вероватно последица ниског *learning rate*-а ($1e-5$) и ниског *LoRA rank*-а (4), који ограничавају флексибилност адаптације модела након одређеног броја корака, међутим повећањем *LoRA rank*-а примећено је и појављивање нежељених података на слици. Већи *batch size* (4) и ограничење градијената допринели су стабилности тренинга, али нису спречили *overfitting* у каснијим корацима. Насупрот томе, *SDXL 1.0* је показао стабилан напредак кроз све кораке, што се може приписати вишем *learning rate*-у ($5e-4$) и вишем *LoRA rank*-у (32), који омогућавају бржу и флексибилнију адаптацију.

Разлике у динамици тренинга између два модела могу се приписати њиховој архитектури и параметрима тренинга.



(a) Базни SD 1.5



(b) SD 1.5 LoRA (step 500)

Слика 2: Упоређивање слика генерисаних базним SD 1.5 моделом и SD 1.5 моделом са LoRA (step 500).



(a) Базни SDXL 1.0



(b) SDXL 1.0 LoRA (step 1500)

Слика 3: Упоређивање слика генерисаних базним SDXL 1.0 моделом и SDXL 1.0 моделом са LoRA (step 1500).

SDXL 1.0, као комплекснији модел, боље искоришћава већи *LoRA rank* и виши *learning rate*, што резултира континуираним побољшањем *FID*-а. *SD 1.5*, са конзервативнијим параметрима, постиже оптималне резултате раније, али је склонији *overfitting*-у. Постигнути резултати показују важност пажљивог избора параметара тренинга, као што су *learning rate*, *LoRA rank* и број корака за постизање оптималних резултата за различите моделе.

VII. Закључак

A. Преглед

Овај рад представља успешан развој система за генерисање визуелног садржаја заснованог на подацима из игре *Elden Ring*, са фокусом на интеграцију мултимодалног учења и дифузионих модела. Развијен је квалитетан скуп података прикупљен са *Elden Ring Wiki* коришћењем техника *web scraping*-а, уз пажљиву примену етичких смерница. Подаци су препроцесирани и обогаћени текстуалним описима генерисаним моделом *BLIP-2*, док је *CLIP* коришћен за филтрирање слика ради постизања стилске конзистентности са естетиком игре. Ови мултимодални приступи омогућили су прецизно мапирање између визуелног и текстуалног модалитета.

Модел *Stable Diffusion 1.5* и *SDXL 1.0* су успешно *fine-tune*-овани применом *LoRA* технике, што је довело

до значајног побољшања визуелног квалитета генерисаних слика. Квантитативна евалуација показала је смањење *FID* вредности за 18.5% за *SD 1.5* (на кораку 500) и 23.3% за *SDXL 1.0* (на кораку 1500) у односу на базне моделе. Квалитативна анализа потврдила је боље детаље и стилску усклађеност, посебно код *SDXL 1.0*, који је показао стабилнији напредак захваљујући сложенијој архитектури и оптимизованим параметрима тренинга. Ови резултати наглашавају ефикасност *LoRA*-е у адаптацији модела за специфичне домене, као и значај пажљивог избора параметара тренинга за спречавање *overfitting*-а.

Кључни доприноси рада укључују:

- креирање структурираног и квалитетног скупа података за тренинг,
- примену мултимодалних модела за обogaћивање података и филтрирање,
- успешан *fine-tuning* дифузионих модела за генерисање стилски конзистентних слика,
- детаљну евалуацију перформанси коришћењем *FID* метрике и квалитативне анализе.

Ови доприноси чине темељ за даљи развој генеративних система у домену видео-игара и дигиталног садржаја.

B. Правци будућег развоја

Иако је развијени систем показао значајне резултате, постоје могућности за даље унапређење. Прво, скуп података може бити проширен укључивањем додатних извора, као што су снимци екрана из игре или кориснички генерисани садржај, чиме би се повећала разноврсност и количина података за тренинг.

Друго, оптимизација параметара тренинга, као што су *LoRA rank*, *learning rate* и *batch size*, могла би се спровести кроз систематско тестирање, попут *grid search*-а ⁷, ради проналажења оптималне конфигурације. Такође, повећање *LoRA rank*-а за *SD 1.5* могло би ублажити проблем *overfitting*-а, уз пажљиву контролу да се избегну нежељени артефакти ⁸.

Треће, примена напреднијих техника *fine-tuning*-а, као што је *DreamBooth*, могла би омогућити прецизније прилагођавање модела специфичним ликовима или сценама из игре. Такође, истраживање нових дифузионих модела или архитектура, попут оних заснованих на трансформерима, могло би додатно побољшати квалитет генерисаних слика.

Четврто, евалуација перформанси могла би бити проширена укључивањем додатних метрика, као што је *CLIP score*, који мери семантичку усклађеност између генерисаних слика и текстуалних упита. Ово би омогућило свеобухватнију процену способности модела да генерише садржај усклађен са описима.

⁷ *Grid search* је техника хиперпараметарске оптимизације која систематски тестира све комбинације унапред дефинисаних вредности параметара ради проналажења оптималне конфигурације [17].

⁸ Артефакти су нежељени визуелни елементи или изобличења у генерисаним сликама, често узроковани несавршеностима у процесу тренинга или моделу [18].

На крају, систем би могао бити примењен на друге домене, попут других видео-игара или уметничких стилова, чиме би се испитала његова генерализација. Интеграција са интерактивним алатима за генерисање садржаја у реалном времену могла би проширити примену система у индустрији видео-игара, омогућавајући креирање персонализованих визуелних елемената за играче или дизајнере.

Literatura

- [1] J. Sohl-Dickstein, E. Weiss, N. Maheswaranathan, and S. Ganguli, "Deep unsupervised learning using nonequilibrium thermodynamics," in *Proc. 32nd Int. Conf. Mach. Learn.*, 2015, pp. 2256–2265.
- [2] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, "High-resolution image synthesis with latent diffusion models," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2022, pp. 10684–10695.
- [3] E. J. Hu et al., "LoRA: Low-rank adaptation of large language models," in *Proc. Int. Conf. Learn. Represent.*, 2022.
- [4] A. Radford et al., "Learning transferable visual models from natural language supervision," in *Proc. 38th Int. Conf. Mach. Learn.*, 2021, pp. 8748–8763.
- [5] J. Li et al., "BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models," in *Proc. 40th Int. Conf. Mach. Learn.*, 2023, pp. 18397–18426.
- [6] T. Brown et al., "Language models are few-shot learners," in *Advances Neural Inf. Process. Syst.*, vol. 33, 2020, pp. 1877–1901.
- [7] Y. Xian, C. H. Lampert, B. Schiele, and Z. Akata, "Zero-shot learning—A comprehensive evaluation of the good, the bad and the ugly," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 41, no. 9, pp. 2251–2265, 2019.
- [8] M. Mitchell et al., "Ethical and social risks of web scraping," in *Proc. ACM Conf. Fairness, Accountability, Transparency*, 2021, pp. 123–134.
- [9] J. Han, M. Kamber, and J. Pei, "Data deduplication techniques for large-scale datasets," *IEEE Trans. Knowl. Data Eng.*, vol. 34, no. 5, pp. 2187–2201, 2022.
- [10] M. Heusel, H. Ramsauer, T. Unterthiner, B. Nessler, and S. Hochreiter, "GANs trained by a two time-scale update rule converge to a local Nash equilibrium," in *Advances Neural Inf. Process. Syst.*, vol. 30, 2017.
- [11] D. C. Dowson and B. V. Landau, "The Fréchet distance between multivariate normal distributions," *J. Multivariate Anal.*, vol. 12, pp. 450–455, 1982.
- [12] S. Ryu, "Low-rank adaptation for fast text-to-image diffusion fine-tuning," GitHub repository, 2022.
- [13] D. Cochar, "Generate images of specific characters using LoRA," *Medium*, 2023.
- [14] A. Shah, M. Polese, and F. A. Galatolo, "Multi-LoRA composition for image generation," *arXiv preprint arXiv:2402.16843*, 2023.
- [15] A. Ramesh et al., "Hierarchical text-conditional image generation with CLIP latents," *arXiv preprint arXiv:2204.06125*, 2022.
- [16] D. Podell et al., "Sdxl: Improving latent diffusion models for high-resolution image synthesis," *arXiv preprint arXiv:2307.01952*, 2023.
- [17] J. Bergstra and Y. Bengio, "Random search for hyper-parameter optimization," *J. Mach. Learn. Res.*, vol. 13, pp. 281–305, 2012.
- [18] T. Karras, S. Laine, M. Aittala, J. Hellsten, J. Lehtinen, and T. Aila, "Analyzing and improving the image quality of StyleGAN," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2020, pp. 8110–8119.